PROJETO DE ANÁLISE DE DADOS · POWER BI

Locadora Rebobina

O que movimentava uma rede de videolocadoras entre 2009 e 2011

Relatório das análises feitas no painel: receita, catálogo, clientes, operação e o efeito do calendário brasileiro (feriados, férias e datas comemorativas) sobre as locações.

R$ 549.434,85
faturamento total

105.078
locações

3.109
clientes ativos

+45,4%
de locações na véspera de feriado

Gustavo Oliveira · Contagem, MG · 2026

O projeto

Cenário, base de dados e como o painel foi construído

Cenário

A **Rebobina** é uma rede fictícia com **3 videolocadoras na RMBH**: Contagem (Eldorado), Belo Horizonte (Savassi) e Betim (Centro). O período analisado vai de **janeiro de 2009 a janeiro de 2011**, época em que a locação física ainda era um bom negócio.

O catálogo usa **3.000 filmes reais** da base pública TMDB 5000, com bilheteria, elenco e diretor reais: 480 lançamentos do período e 2.520 títulos que já estavam no acervo. Lojas, clientes, estoque, locações e pagamentos foram **simulados com regras de negócio**, descritas no fim deste relatório.

Modelo de dados

Modelo estrela com duas tabelas de fato e seis dimensões:

- **fato_locacao**: uma linha por filme alugado (105 mil)
- **fato_pagamento**: locações e multas (125 mil), base do faturamento em R$
- **dim_filme**, **dim_ator** e a ponte filme × ator (muitos-para-muitos)
- **dim_cliente**, **dim_loja**
- **dim_calendario** com feriados nacionais, vésperas, férias escolares, datas comemorativas e jogos do Brasil na Copa

Python monta todas as tabelas (inclusive as saídas dos modelos); o **DAX** traz 65 medidas e um grupo de cálculo. A divisão completa está nas próximas duas páginas.

Ferramentas e entrega

Python (pandas, NumPy, scikit-learn) para a simulação, a previsão de demanda, a otimização de cópias e o modelo de abandono · **SQL Server** com scripts de criação, carga e views de BI · **Power BI** em formato de projeto (.pbip: modelo em TMDL e relatório em PBIR), com os dados embutidos, pronto para abrir e atualizar · **GitHub** com o pipeline que gera tudo a partir da base original.

O painel tem 6 páginas: Visão Geral, Filmes e Atores, Clientes e Operação, Sazonalidade e Datas, Estoque e Retenção, e Previsões e Recomendações. Os filtros de loja, categoria e mês são sincronizados entre as páginas.

Como o painel foi montado

Onde entra Python, Power Query e DAX, tabela por tabela

PYTHON **Monta todas as tabelas**

pandas, NumPy e scikit-learn: simulação, calendário, colunas linha a linha e modelos.

POWER QUERY **Carrega os dados**

Lê os CSVs embutidos no arquivo, aplica os tipos e gera a tabela meses_relativos.

DAX **Calcula no relatório**

65 medidas e 1 grupo de cálculo. Nenhuma coluna calculada: o DAX só agrega e compara.

SQL **Base relacional (opcional)**

Scripts SQL Server com as mesmas tabelas e views de BI, para quem quiser rodar no banco.

TABELA NO POWER BI	MONTADA EM	O QUE TEM
`dim_calendario`	PYTHON	761 dias com feriados nacionais, vésperas, férias escolares de MG, datas comemorativas, Copa 2010 e Mês Índice.
`dim_filme`	PYTHON	3.000 filmes do TMDB com título em português, categoria, perfil (lançamento, acervo, clássico), tema e valores em R$.
`dim_ator · ponte_filme_ator`	PYTHON	Elenco dos filmes e a tabela ponte da relação muitos-para-muitos.
`dim_loja · dim_copia`	PYTHON	3 lojas e 11.973 cópias: 3 para os sucessos, 2 para lançamentos, 1 para o acervo.
`dim_cliente`	PYTHON	3.200 clientes com faixa etária, coorte de entrada e risco de abandono vindo do modelo (scikit-learn).
`fato_locacao`	PYTHON	105.078 locações simuladas dia a dia: procura, cópia livre, promoção, atraso e fim da ocupação.
`fato_pagamento`	PYTHON	125.080 pagamentos em R$: locações, multas e acordos de multa.
`fato_demanda_nao_atendida`	PYTHON	4.120 tentativas de aluguel sem cópia livre na loja.
`previsao_lancamentos · otimizacao_copias · importancia_churn · metricas_modelos`	PYTHON	Saídas dos três modelos: demanda prevista, cópias ideais, fatores de abandono e métricas de validação.
`meses_relativos`	POWER QUERY	Sequência de 0 a 24 gerada em M (List.Numbers). Tabela desconectada usada pela coorte.
`Comparação de Tempo`	DAX	Grupo de cálculo: período atual, mês anterior, ano anterior, acumulado no ano e variação %.
`_Medidas`	DAX	65 medidas em 9 pastas: receita, volume, catálogo, operação, calendário, rankings, estoque, retenção e modelos.

Resumo: as 14 tabelas de dados nascem em **Python**; o **Power Query** só carrega e tipa; o **DAX** não cria tabelas nem colunas, ele calcula as 65 medidas e o grupo de cálculo em cima delas.

Python × DAX na prática

Um trecho real de cada e a regra usada para dividir o trabalho

DAX 65 medidas em 9 pastas + grupo de cálculo

11	**1. Receita** — Faturamento, ticket médio, descontos e variação mês a mês
6	**2. Volume** — Locações, clientes ativos e locações por cliente
7	**3. Catálogo** — Filmes no catálogo, % de lançamentos, locações por título
5	**4. Operação** — % de devoluções com atraso, locações em aberto, dias com o cliente
5	**5. Calendário** — Médias por tipo de dia e efeito da véspera de feriado
6	**6. Rankings** — Top N com RANKX + ALLSELECTED (respeita os filtros)
9	**7. Estoque** — Ocupação das cópias por sobreposição de intervalos
4	**8. Retenção** — Coorte com TREATAS e tabela desconectada
12	**9. Modelos (Python)** — Medidas que leem as tabelas geradas em Python

Grupo de cálculo "Comparação de Tempo": 5 itens (período atual, mês anterior, mesmo período do ano anterior, acumulado no ano e variação %) que se aplicam a qualquer medida por um único filtro na Visão Geral.

DAX

ocupação do estoque: cada locação é um intervalo de datas

```
Dias Alugados =
VAR _ini = MIN ( dim_calendario[Data] )
VAR _fim = MAX ( dim_calendario[Data] ) + 1
RETURN SUMX (
    FILTER (
        CALCULATETABLE ( fato_locacao,
            REMOVEFILTERS ( dim_calendario ) ),
        fato_locacao[data_locacao] < _fim
            && fato_locacao[data_fim_ocupacao] > _ini ),
    INT ( MIN ( _fim, fato_locacao[data_fim_ocupacao] )
        - MAX ( _ini, fato_locacao[data_locacao] ) ) )
```

PYTHON

o modelo roda antes; o Power BI só lê o resultado

```
# analises_python.py · previsão de demanda dos lançamentos
X["log_bilheteria"] = np.log1p(lanc.revenue)
X["log_votos"]      = np.log1p(lanc.vote_count)
X["mes_sen"], X["mes_cos"] = np.sin(2*np.pi*m/12), np.cos(2*np.pi*m/12)
y = np.log1p(lanc.demanda_8sem)
treino = comp & (lanc.chegada <  date(2010, 5, 1)).values   # validação
teste  = comp & (lanc.chegada >= date(2010, 5, 1)).values   # temporal
gb = HistGradientBoostingRegressor(max_iter=400, learning_rate=0.04)
gb.fit(X[treino], y[treino])     # vira a tabela previsao_lancamentos
```

A regra de divisão

- **Python** faz tudo o que é **linha a linha** ou depende de modelo: simular, classificar o dia, marcar a coorte, prever.
- **DAX** faz tudo o que **muda com o filtro**: somas, percentuais, rankings, ocupação, retenção e comparação de tempo.
- Assim o modelo fica leve (sem colunas calculadas) e cada número do painel responde aos filtros de loja, categoria e mês.

1. Visão Geral

Receita, volume e desempenho das lojas

MONTADO COM PYTHON DAX

Python: fato_pagamento e dim_loja · DAX: Faturamento, Ticket Médio, Variação vs Mês Anterior

R$ 549.434,85
faturamento

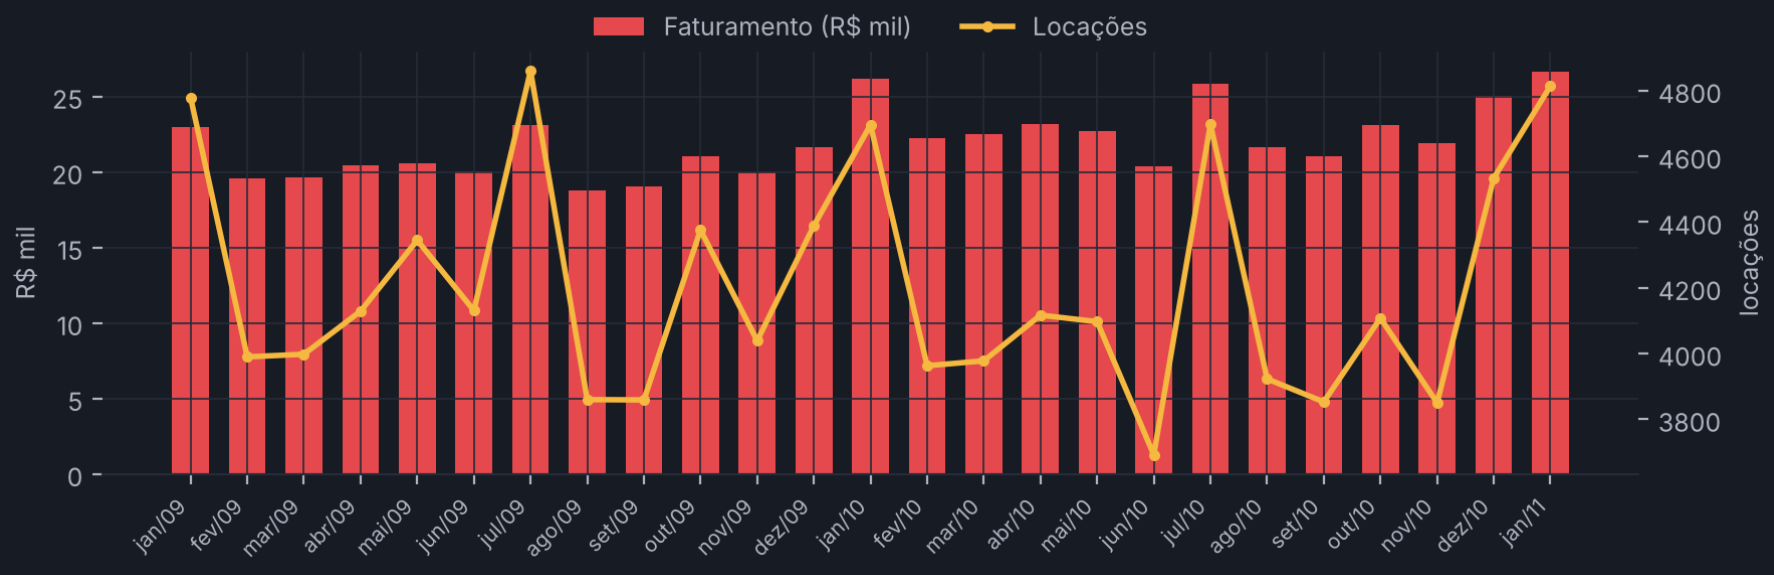
105.078
locações

R$ 5,23
ticket médio por locação

16,0%
da receita vem de multas

R$ 28.766,62
em descontos concedidos

Faturamento (colunas) e locações (linha) por mês



O que os números mostram

- O volume ficou estável (cerca de 4.200 locações por mês), mas o faturamento subiu em 2010 por causa do **reajuste da tabela de preços**.
- Os picos de janeiro, julho e dezembro coincidem com as **férias escolares**.
- A loja da Savassi (BH) responde por **40,4%** da receita.

Receita por categoria (gênero principal)

Drama, comédia e ação lideram: **Drama** R$ 105,7 mil, **Comédia** R$ 104,0 mil, **Ação** R$ 92,6 mil, **Aventura** R$ 77,8 mil. Animação e terror ficam atrás no total, mas são os gêneros mais sensíveis ao calendário (página 4).

2. Filmes e Atores

Catálogo, títulos de destaque e o peso da bilheteria

MONTADO COM PYTHON DAX

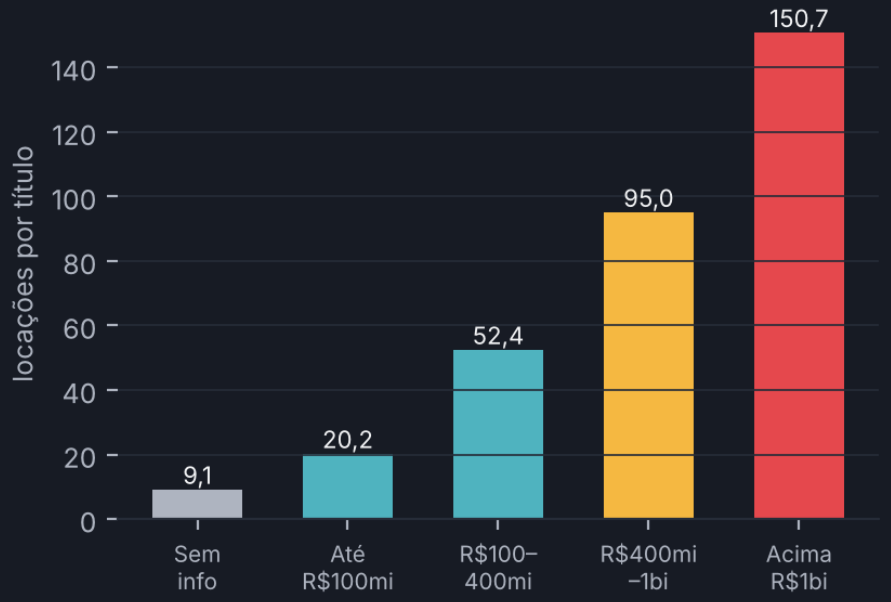
Python: dim_filme, dim_ator e ponte · DAX: rankings Top N com RANKX

3.000	2.894	30,3%	R$ 4,39	36,3
filmes no catálogo	filmes alugados ao menos 1 vez	das locações são lançamentos	preço médio pago	locações por título

Filmes mais alugados



Locações por título × bilheteria do filme



Leitura

- **Bilheteria explica a procura:** filmes acima de R$ 1 bi de bilheteria tiveram em média **150,7** locações por título, contra **20,2** dos que fizeram até R$ 100 mi. Os 15% de maior sucesso têm 3 cópias por loja e mesmo assim chegam a esgotar.
- **Lançamentos** do período concentram 28,7% das locações; os **clássicos** mantêm saída constante (7.710 locações).
- Atores com mais locações (soma dos filmes em que aparecem): Brad Pitt, Tom Hanks e Johnny Depp.

3. Clientes e Operação

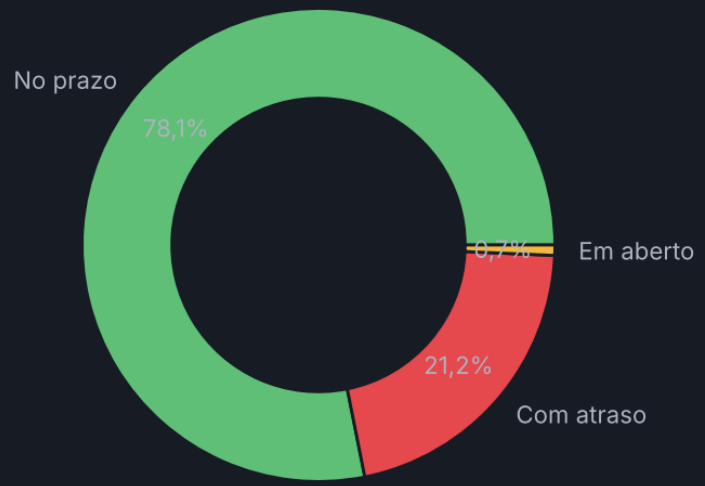
Base de clientes, devoluções, multas e promoções

MONTADO COM PYTHON DAX

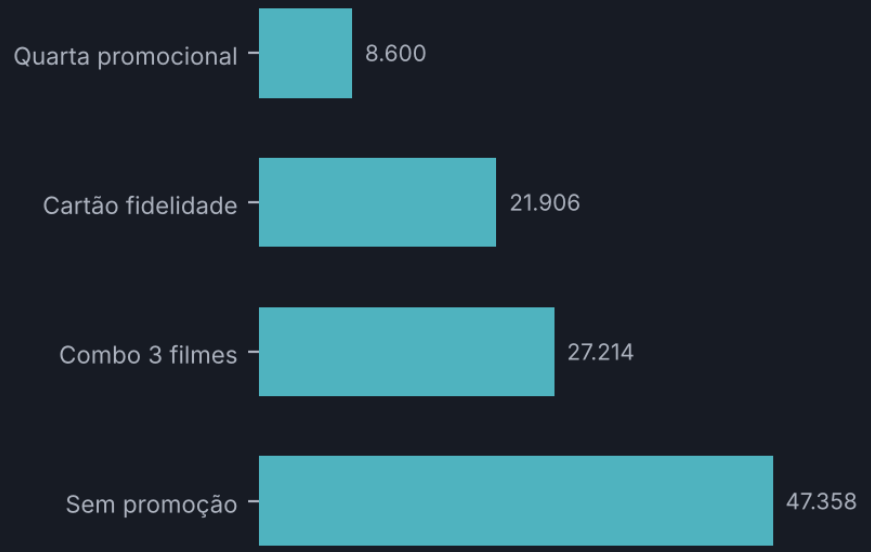
Python: fato_locacao (atrasos, promoções) · DAX: % Devoluções com Atraso, Multas Pendentes

3.109	33,8	21,3%	R$ 87.715,75	R$ 9.949,72
clientes ativos	locações por cliente	devoluções com atraso	receita de multas	multas não pagas

Status das devoluções



Locações por tipo de promoção



Leitura

- **Multas são relevantes:** 21,3% das devoluções atrasam e as multas somam 16,0% da receita; parte é negociada no balcão (30% de desconto) e R$ 9.949,72 ficaram sem pagar.
- **Promoções:** 54,9% das locações tiveram algum desconto (combo de 3 filmes, cartão fidelidade ou quarta promocional), somando R$ 28.766,62.
- **Perfil:** clientes de 35 a 59 anos fazem 59,5% das locações; os bairros de BH (Gutierrez, Santo Antônio, Prado) lideram a receita.

4. Sazonalidade e Datas

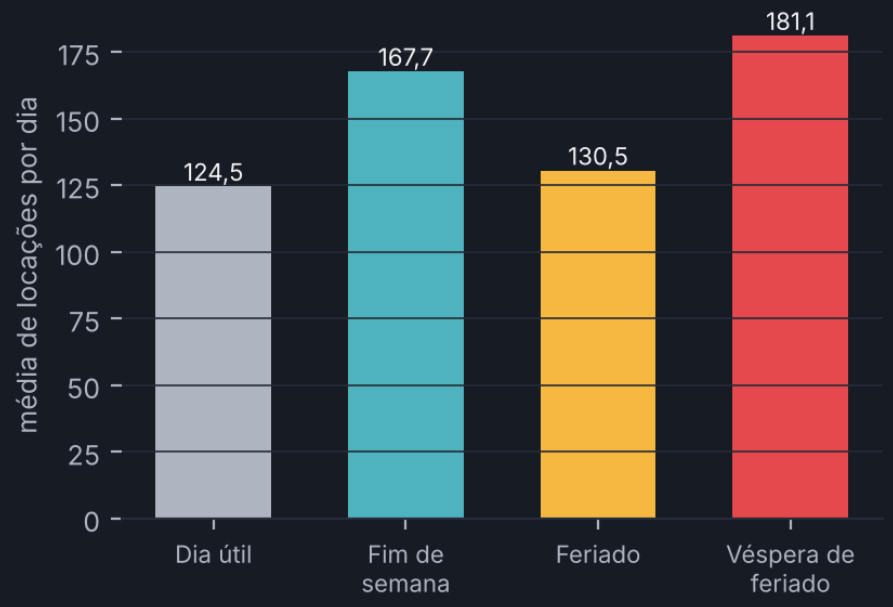
Feriados, vésperas, férias e datas comemorativas

MONTADO COM PYTHON DAX

Python: feriados e vésperas na dim_calendario · DAX: Efeito Véspera de Feriado %

138,1	181,1	124,5	+45,4%	16.247
locações por dia (média)	média em vésperas de feriado	média em dias úteis	efeito da véspera	locações de filmes temáticos

Média diária de locações por tipo de dia



Média diária em datas comemorativas



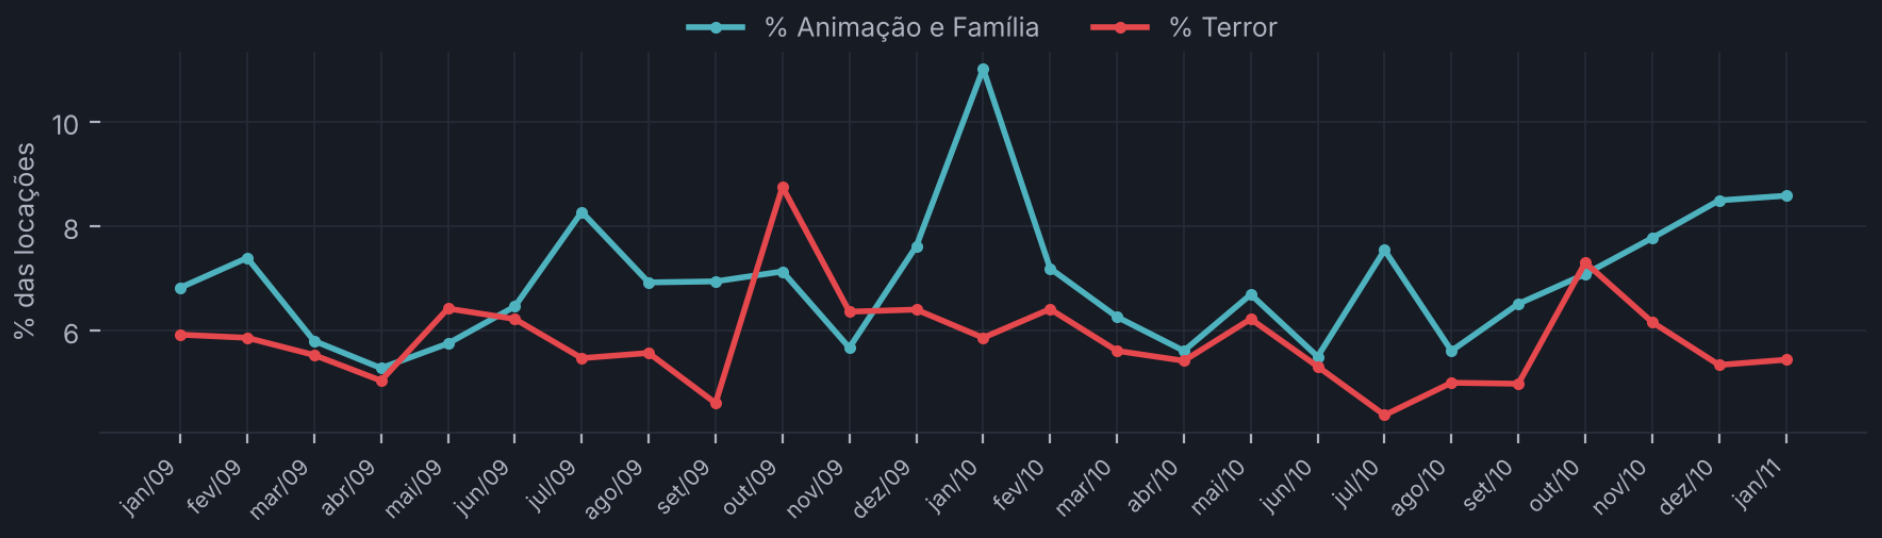
Leitura

- **Véspera de feriado é o melhor dia do calendário:** 181,1 locações por dia, 45,4% acima de um dia útil comum e acima até do fim de semana (167,7). O cliente se abastece antes do feriado.
- **Carnaval** (173,3/dia), **Semana Santa** e **Natal** são as datas mais fortes. Nos dias de jogo do Brasil na Copa de 2010 o movimento caiu quase pela metade.
- Nas datas comemorativas, os filmes ligados ao tema (Natal, Dia das Mães, Dia dos Pais, Páscoa, futebol na Copa) chegam a ter o triplo da procura.

4. Sazonalidade e Datas

Gêneros que mudam com o calendário

Participação de Animação/Família e de Terror nas locações, por mês



Férias e Semana das Crianças

Nas férias escolares (janeiro, julho e segunda quinzena de dezembro), Animação e Família sobem para **8,5%** das locações, contra **6,4%** no período letivo. Outro pico aparece na **Semana das Crianças** (5 a 12 de outubro).

Para o negócio: reforçar o estoque de animações antes das férias e montar vitrines temáticas.

Outubro do terror

Em outubro, terror representa **8,1%** das locações, contra **5,6%** no resto do ano. O pico fica na última semana, perto do Halloween, quando filmes com temas como zumbis, vampiros e casas assombradas têm o dobro da procura.

Para o negócio: antecipar a compra de cópias de terror e destacar o gênero em outubro.

5. Estoque e Retenção

DAX avançado: ocupação das cópias e coorte de clientes

MONTADO COM POWER QUERY DAX

Power Query: meses_relativos · DAX: Taxa de Ocupação, Retenção % (TREATAS)

5,1% ocupação média das cópias

8,7% ocupação dos lançamentos

4.120 tentativas sem cópia livre

45,0% retenção média no 3º mês

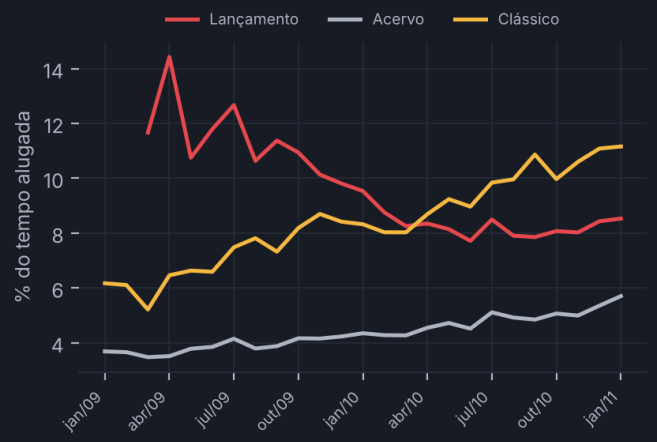
40,9% retenção média no 12º mês

Coorte de retenção (% que voltou a alugar)

	0	1	2	3	4	5	6	7	8	9	10	11	12
jan/09	100	66	65	62	62	60	64	58	56	55	54	54	55
fev/09	100	48	49	53	46	54	40	42	42	39	43	44	42
mar/09	100	48	50	46	46	46	39	31	39	34	38	32	36
abr/09	100	43	44	45	39	37	44	38	40	37	38	34	38
mai/09	100	37	46	41	46	42	41	43	44	31	30	33	35
jun/09	100	52	44	38	50	41	38	39	36	36	32	29	29
jul/09	100	44	45	45	42	41	53	37	42	41	43	41	52
ago/09	100	59	41	47	43	57	53	51	49	44	37	43	50
set/09	100	51	47	49	51	53	50	47	43	42	47	41	42
out/09	100	48	55	50	42	45	52	49	37	46	39	49	44
nov/09	100	48	44	46	31	41	38	36	34	43	33	30	41
dez/09	100	45	52	42	42	47	42	47	38	37	35	43	35
jan/10	100	46	39	46	34	25	18	30	31	25	35	23	32
fev/10	100	38	33	40	48	42	40	35	38	32	43	38	
mar/10	100	46	46	44	29	40	31	29	27	38	33		
abr/10	100	43	44	41	37	37	39	41	33	24			
mai/10	100	40	43	45	36	40	45	43	40				
jun/10	100	44	33	36	53	50	33	42					
jul/10	100	39	39	49	39	39	45						
ago/10	100	40	49	49	49	37							
set/10	100	41	34	31	45								
out/10	100	30	40	43									
nov/10	100	45	35										
dez/10	100	33											
jan/11	100												

meses depois da 1ª locação

Ocupação das cópias por mês



Como foi calculado e o que mostra

Ocupação = dias em que cada cópia esteve com um cliente ÷ dias em que ela já estava no acervo. Em DAX, cada locação é um intervalo (retirada até devolução) cruzado com o período filtrado. Lançamentos ficam 8,7% do tempo fora, o dobro do acervo (4,4%).

Coorte: tabela desconectada de meses relativos + TREATAS. Cerca de 45% voltam no 3º mês e 41% no 12º; a coorte de jan/09 reúne os clientes antigos e retém mais.

6. Previsões e Recomendações

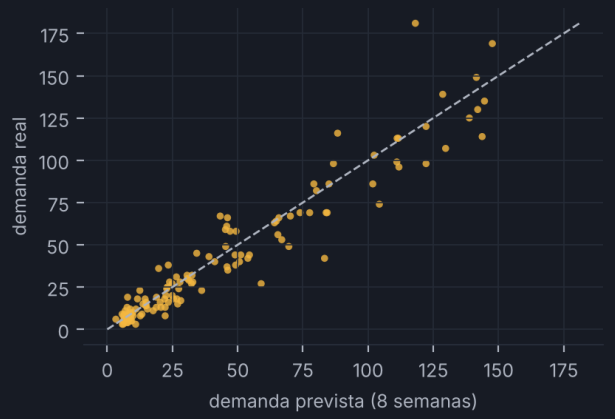
Modelos em Python: demanda, cópias ideais e risco de abandono

MONTADO COM PYTHON DAX

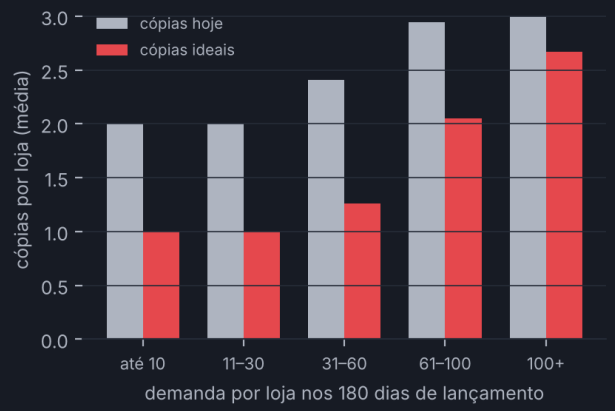
Python (scikit-learn): as 4 tabelas dos modelos · DAX só lê os resultados

0,91	7,7	R$ 38.413,12	0,773	128
R^2 da previsão de demanda	erro médio (locações em 8 semanas)	ganho com o nº ideal de cópias	AUC do modelo de abandono	clientes em risco alto

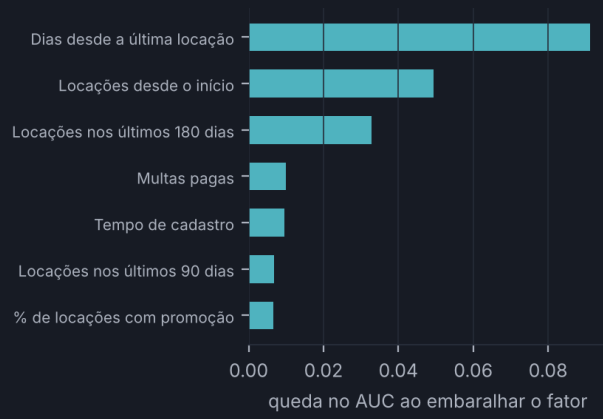
Previsto × real (teste)



Cópias por loja: hoje × ideal



O que pesa no risco de abandono



Leitura

- **Previsão de demanda:** gradient boosting com bilheteria, votos, popularidade, gênero e mês de chegada prevê a procura das 8 primeiras semanas. Validação temporal (treino até abr/10, teste mai–dez/10): R^2 0,91, erro médio de 7,7 locações, contra 9,4 da regressão linear.
- **Cópias ideais:** comparando a receita de cada cópia extra com seu custo líquido (compra menos revenda), 1.060 dos 1.095 pares filme × loja têm cópias demais. Comprar 1 cópia para lançamentos medianos e 3 só para os sucessos renderia R$ 38.413,12 a mais.
- **Abandono:** o modelo (AUC 0,773) concentra nos 20% de maior risco 44,6% dos abandonos reais; o fator mais forte é o tempo desde a última locação.

7. Recomendações

O que a rede deveria fazer a partir das análises

1

Mudar a política de compra de cópias

Usar a previsão de demanda para decidir as cópias de cada lançamento: 1 por loja para a maioria e 3 só para os sucessos. Impacto estimado: R$ 38.413,12 na fase de lançamento.

2

Abastecer a loja antes dos feriados

Vésperas de feriado têm 45,4% mais locações que um dia útil. Reforçar equipe, devoluções e lançamentos em destaque nesses dias.

3

Vitrines temáticas pelo calendário

Animação nas férias e na Semana das Crianças, terror em outubro, filmes de Natal em dezembro, de mães e pais nas semanas das datas e de futebol em ano de Copa.

4

Agir sobre clientes em risco

Oferecer promoção para os 128 clientes em risco alto antes que passem de 60 dias sem alugar. Receita em jogo nos próximos meses: R$ 10.646,11.

5

Rever multas e prazos

Multas são 16,0% da receita, mas 21,3% das devoluções atrasam. Lembretes de devolução e prazo de 2 dias em lançamentos de baixa procura podem reduzir atrito sem perder receita.

Metodologia

Regras de negócio da simulação e limitações

Regras usadas na simulação

Procura por filme: combina bilheteria (50%), votos (35%) e popularidade (15%) do TMDB. Lançamentos chegam 2 a 3,5 meses após o cinema, com pico nas primeiras semanas; clássicos (antes de 1990, nota ≥ 7) não perdem procura.

Estoque: os 15% de maior sucesso têm 3 cópias por loja; lançamentos têm 2; o acervo, 1. Sem cópia livre, o cliente troca de filme ou desiste.

Calendário: feriados nacionais de 2009 a 2011, vésperas (+45%), férias escolares de MG, datas comemorativas com filmes temáticos identificados por palavras-chave do TMDB, Copa de 2010.

Preços (R$): lançamento 5,89 → 6,49; catálogo 3,79 → 4,39; clássico 2,99 → 3,29 (reajuste em 2010). Quarta promocional (−25% em catálogo e clássico), combo de 3 filmes (−10%), cartão fidelidade (−7%).

Devolução: cerca de 21% com atraso; multa diária de R$ 1,89 a R$ 3,19, com acordo de 30% em parte dos casos.

Modelos: previsão com HistGradientBoosting (alvo em log, validação temporal); cópias ideais maximizando receita − custo líquido por cópia (R$ 15 de revenda) nos 180 dias de lançamento; abandono = nenhuma locação nos 90 dias seguintes, com fotos mensais dos clientes, treino até abr/10 e teste depois.

Limitações e cuidados

- Os dados de locação são **simulados**: servem para estudo e portfólio, não representam uma empresa real.
- Bilheteria e orçamento foram convertidos de dólar para real pelo **câmbio médio de 2010 (R$ 1,76)**.
- Os **3.000 títulos estão em português**: título oficial de lançamento no Brasil sempre que existe e tradução própria para filmes que não chegaram ao circuito brasileiro. Títulos repetidos levam o ano entre parênteses.
- A **classificação indicativa** foi estimada pelo gênero, porque a base não traz essa informação.
- As médias diárias por data comemorativa incluem todas as lojas e todos os gêneros.
- A otimização de cópias usa a demanda observada (locações + tentativas sem cópia); clientes que desistiram sem tentar não aparecem, então a falta de estoque pode estar subestimada.