GUIA PRÁTICO

Como apresentar o projeto Locadora Rebobina

Em 7 minutos, numa entrevista ou num vídeo para o portfólio

1 Comece pelo problema, não pela ferramenta

Recrutador quer ver raciocínio de negócio; a técnica entra como prova.

2 Mostre 3 números e 1 recomendação

Ninguém lembra de 20 gráficos. Todos lembram de "+45% na véspera de feriado".

3 Abra o código uma vez

Uma medida DAX e um trecho do Python bastam para provar que foi você que fez.

Antes de começar

Preparação de 10 minutos que evita os erros mais comuns

Checklist técnico

- Abra o **.pbix** salvo (não o .pbip) e confirme que os dados já foram atualizados.
- Limpe todos os filtros e deixe a página **Visão Geral** aberta.
- Deixe o Power BI em **tela cheia** (Exibir > Tela inteira) e o zoom em "Ajustar à página".
- Abra em abas separadas: o **repositório no GitHub**, o arquivo **analises_python.py** e a medida **Retenção %** no modo de exibição TMDL do Power BI.
- Tenha o **PDF das análises** aberto como plano B, caso o Power BI trave.
- Confira se os números do painel batem com os do PDF de análises.
- Feche notificações e o e-mail. Se for gravar, use 1920×1080 e microfone próximo.

Os números que você precisa saber de cor

R$ 549 mil	faturamento em 25 meses, 3 lojas
105.078	locações de 3.000 filmes reais
+45%	de locações na véspera de feriado
16%	da receita vem de multas
0,91	R^2 da previsão de demanda dos lançamentos
R$ 38.413,12	de ganho com o número ideal de cópias
0,773	de AUC no modelo de abandono de clientes

Python × DAX: quem fez o quê

Saiba apontar, tabela por tabela, com o que cada parte foi montada

PYTHON — Monta todas as tabelas

pandas, NumPy e scikit-learn: simulação, calendário, colunas linha a linha e modelos.

POWER QUERY — Carrega os dados

Lê os CSVs embutidos no arquivo, aplica os tipos e gera a tabela meses_relativos.

DAX — Calcula no relatório

65 medidas e 1 grupo de cálculo. Nenhuma coluna calculada: o DAX só agrega e compara.

SQL — Base relacional (opcional)

Scripts SQL Server com as mesmas tabelas e views de BI, para quem quiser rodar no banco.

TABELA NO POWER BI	MONTADA EM	O QUE TEM
`dim_calendario`	PYTHON	761 dias com feriados nacionais, vésperas, férias escolares de MG, datas comemorativas, Copa 2010 e Mês Índice.
`dim_filme`	PYTHON	3.000 filmes do TMDB com título em português, categoria, perfil (lançamento, acervo, clássico), tema e valores em R$.
`dim_ator · ponte_filme_ator`	PYTHON	Elenco dos filmes e a tabela ponte da relação muitos-para-muitos.
`dim_loja · dim_copia`	PYTHON	3 lojas e 11.973 cópias: 3 para os sucessos, 2 para lançamentos, 1 para o acervo.
`dim_cliente`	PYTHON	3.200 clientes com faixa etária, coorte de entrada e risco de abandono vindo do modelo (scikit-learn).
`fato_locacao`	PYTHON	105.078 locações simuladas dia a dia: procura, cópia livre, promoção, atraso e fim da ocupação.
`fato_pagamento`	PYTHON	125.080 pagamentos em R$: locações, multas e acordos de multa.
`fato_demanda_nao_atendida`	PYTHON	4.120 tentativas de aluguel sem cópia livre na loja.
`previsao_lancamentos · otimizacao_copias · importancia_churn · metricas_modelos`	PYTHON	Saídas dos três modelos: demanda prevista, cópias ideais, fatores de abandono e métricas de validação.
`meses_relativos`	POWER QUERY	Sequência de 0 a 24 gerada em M (List.Numbers). Tabela desconectada usada pela coorte.
`Comparação de Tempo`	DAX	Grupo de cálculo: período atual, mês anterior, ano anterior, acumulado no ano e variação %.
`_Medidas`	DAX	65 medidas em 9 pastas: receita, volume, catálogo, operação, calendário, rankings, estoque, retenção e modelos.

Fale: "Tudo que é linha a linha eu fiz em Python, inclusive o calendário e os modelos. O Power Query só carrega. O DAX não cria tabela nem coluna: ele faz o que muda com o filtro, como ocupação, retenção, rankings e comparação de tempo."

Python × DAX: o código que você vai mostrar

Os dois trechos da etapa 4. Abra cada um por 20 segundos, no máximo

DAX — 65 medidas em 9 pastas + grupo de cálculo

11	**1. Receita** — Faturamento, ticket médio, descontos e variação mês a mês
6	**2. Volume** — Locações, clientes ativos e locações por cliente
7	**3. Catálogo** — Filmes no catálogo, % de lançamentos, locações por título
5	**4. Operação** — % de devoluções com atraso, locações em aberto, dias com o cliente
5	**5. Calendário** — Médias por tipo de dia e efeito da véspera de feriado
6	**6. Rankings** — Top N com RANKX + ALLSELECTED (respeita os filtros)
9	**7. Estoque** — Ocupação das cópias por sobreposição de intervalos
4	**8. Retenção** — Coorte com TREATAS e tabela desconectada
12	**9. Modelos (Python)** — Medidas que leem as tabelas geradas em Python

Grupo de cálculo "Comparação de Tempo": 5 itens (período atual, mês anterior, mesmo período do ano anterior, acumulado no ano e variação %) que se aplicam a qualquer medida por um único filtro na Visão Geral.

DAX — ocupação do estoque: cada locação é um intervalo de datas

```
Dias Alugados =
VAR _ini = MIN ( dim_calendario[Data] )
VAR _fim = MAX ( dim_calendario[Data] ) + 1
RETURN SUMX (
    FILTER (
        CALCULATETABLE ( fato_locacao,
            REMOVEFILTERS ( dim_calendario ) ),
        fato_locacao[data_locacao] < _fim
            && fato_locacao[data_fim_ocupacao] > _ini ),
    INT ( MIN ( _fim, fato_locacao[data_fim_ocupacao] )
        - MAX ( _ini, fato_locacao[data_locacao] ) ) )
```

PYTHON — o modelo roda antes; o Power BI só lê o resultado

```
# analises_python.py · previsão de demanda dos lançamentos
X["log_bilheteria"] = np.log1p(lanc.revenue)
X["log_votos"]      = np.log1p(lanc.vote_count)
X["mes_sen"], X["mes_cos"] = np.sin(2*np.pi*m/12), np.cos(2*np.pi*m/12)
y = np.log1p(lanc.demanda_8sem)
treino = comp & (lanc.chegada <  date(2010, 5, 1)).values   # validação
teste  = comp & (lanc.chegada >= date(2010, 5, 1)).values   # temporal
gb = HistGradientBoostingRegressor(max_iter=400, learning_rate=0.04)
gb.fit(X[treino], y[treino])     # vira a tabela previsao_lancamentos
```

A regra de divisão

- **Python** faz tudo o que é **linha a linha** ou depende de modelo: simular, classificar o dia, marcar a coorte, prever.
- **DAX** faz tudo o que **muda com o filtro**: somas, percentuais, rankings, ocupação, retenção e comparação de tempo.
- Assim o modelo fica leve (sem colunas calculadas) e cada número do painel responde aos filtros de loja, categoria e mês.

O roteiro em 6 etapas (1/2)

7 minutos no total · use o relógio como guia, não como regra

0:00 – 0:45

1. O problema

Faça: Página Visão Geral aberta, sem clicar em nada. Olhe para a câmera ou para o entrevistador.

Fale: "Imaginei uma rede de 3 videolocadoras em BH entre 2009 e 2011 e me fiz três perguntas de dono: o que faz um filme alugar, quando o movimento sobe e onde estou perdendo dinheiro. O projeto responde isso de ponta a ponta: dos dados brutos até recomendações em reais."

0:45 – 1:45 PYTHON POWER QUERY

2. Os dados e o modelo

Faça: Mostre rapidamente a exibição de modelo do Power BI (o modelo estrela) e, se quiser, o README do GitHub.

Fale: "Os filmes são reais: 3.000 títulos da base pública do TMDB, com bilheteria e elenco. Clientes, estoque e locações eu simulei em Python com regras de negócio, como feriados, férias e limite de cópias. Todas as tabelas, inclusive o calendário com os feriados brasileiros, saem de um pipeline em Python que qualquer pessoa pode rodar; o Power Query só carrega."

1:45 – 3:30

3. O tour pelo painel

Faça: Visão Geral → clique numa loja na rosca. Filmes e Atores → aponte a coluna de bilheteria. Sazonalidade → aponte a véspera de feriado. Não leia gráfico por gráfico: aponte só o achado de cada página.

Fale: "O faturamento cresce em 2010 com o mesmo volume, porque houve reajuste. Filmes acima de R$ 1 bi de bilheteria alugam 151 vezes por título, contra 20 dos pequenos. E o melhor dia do ano não é o sábado, é a véspera de feriado: 45% acima de um dia útil."

O roteiro em 6 etapas (2/2)

A parte técnica vem depois do negócio, e não antes

3:30 – 5:30 DAX PYTHON

4. Os destaques técnicos

Faça: **[DAX]** Página Estoque e Retenção → mostre a matriz de coorte e abra a medida **Retenção %** (TREATAS + tabela desconectada). **[PYTHON]** Página Previsões → mostre o previsto × real e abra o **analises_python.py** por 20 segundos.

Fale: "No DAX, as partes mais difíceis foram a ocupação do estoque, que cruza cada locação, um intervalo de datas, com o período filtrado, e a coorte, que usa uma tabela desconectada. No Python, treinei um gradient boosting para prever a demanda dos lançamentos, com validação temporal: R^2 de 0,91, contra a regressão linear como base. E um modelo de abandono com AUC de 0,773."

5:30 – 6:30

5. As recomendações

Faça: Página Previsões → aponte a tabela de cópias atuais × ideais e o card de ganho. Se for vídeo, mostre a página de Recomendações do PDF.

Fale: "A análise que mais vale dinheiro é a de estoque: a rede compra 2 cópias por loja para todo lançamento, e a demanda só justifica isso nos sucessos. Ajustar a compra com a previsão renderia cerca de R$ 38.413,12. Também recomendo reforçar o estoque antes dos feriados e agir sobre os 128 clientes em risco alto de abandono."

6:30 – 7:00

6. O fechamento

Faça: Volte para a Visão Geral. Termine olhando para a pessoa, e não para a tela.

Fale: "Os dados de locação são simulados, então eu não venderia esses números como verdade de mercado. O valor está no processo: fazer a pergunta certa, modelar, validar e transformar em decisão. Se eu tivesse dados reais, o próximo passo seria testar a nova política de cópias em uma loja antes de levar para as outras."

Perguntas que provavelmente vão fazer

Respostas curtas: 20 a 30 segundos cada

Por que dados simulados?

Não existe base pública de locadora com esse nível de detalhe. Usei filmes reais e simulei o comportamento com regras explícitas, que estão documentadas. Isso me permitiu testar se as análises recuperam os padrões que eu coloquei: a véspera de feriado e o efeito da bilheteria aparecem nos números.

Como você sabe que os números estão certos?

Conferi por três caminhos: os scripts SQL e o Power BI chegam ao mesmo faturamento; recalculei os indicadores em Python e conferi com o painel; e os arquivos do relatório passaram nos esquemas oficiais da Microsoft.

Como você validou o modelo de previsão?

Com validação temporal: treinei com os lançamentos até abril de 2010 e testei com os seguintes, como seria na vida real. Comparei com uma regressão linear como base e olhei o erro em locações, que é o que importa para comprar cópias.

Por que gradient boosting?

Porque a relação entre bilheteria, votos e demanda não é linear e há interação com o mês de chegada. Ele ganhou da regressão linear, mas mantive a regressão no projeto como comparação: não uso o modelo mais complexo sem provar que ele vale a pena.

Qual foi a parte mais difícil?

A ocupação do estoque em DAX. Uma locação é um intervalo de datas, e o filtro do relatório é outro intervalo; precisei remover o filtro de calendário e recalcular a sobreposição linha a linha, sem perder os filtros de filme e loja.

O que você faria diferente?

Com dados reais, eu mediria também quem desistiu sem pedir o filme, porque a falta de estoque provavelmente está subestimada. E faria um teste A/B da promoção de quarta antes de concluir que ela traz clientes novos.

Versões curtas

Para quando você só tem 30 segundos ou 2 minutos

Pitch de 30 segundos (entrevista, networking)

"Construí um projeto completo de dados sobre uma rede de videolocadoras: 3.000 filmes reais, 105 mil locações simuladas, modelo estrela, 65 medidas DAX e três análises em Python (previsão de demanda, cópias ideais e abandono). O achado que mais gosto é que a véspera de feriado vende 45% mais que um dia comum, e a recomendação que mais vale dinheiro é ajustar a compra de cópias com a previsão de demanda, o que renderia cerca de R$ 38.413,12."

Versão de 2 minutos (vídeo curto)

1. **Problema** (15 s): três perguntas de dono de locadora.
2. **Dados** (20 s): filmes reais, comportamento simulado, modelo estrela.
3. **Três achados** (45 s): bilheteria × procura, véspera de feriado, gêneros que mudam com o calendário.
4. **Uma prova técnica** (20 s): a matriz de coorte ou o gráfico previsto × real.
5. **Recomendação** (20 s): política de cópias com o ganho em R$.

Post no LinkedIn

Gancho: "Em qual dia do ano uma locadora mais alugava? Não era sábado."
Corpo: 3 achados em tópicos curtos, cada um com um número.
Prova: GIF de 15 s navegando pelo painel + print da matriz de coorte.
Técnica: 1 linha com as ferramentas (Power BI, DAX, Python, SQL Server).
Final: link do GitHub e uma pergunta para gerar comentários.

Erros que derrubam uma boa apresentação

E como evitá-los

× Ler o painel gráfico por gráfico

Em vez disso: Aponte só o achado de cada página e siga em frente.

× Começar pela ferramenta

Em vez disso: “Usei Power BI e Python” não prende ninguém. Comece pela pergunta de negócio.

× Esconder que os dados são simulados

Em vez disso: Diga logo no início. Transparência conta pontos, e esconder tira credibilidade se perguntarem.

× Prometer precisão que não existe

Em vez disso: Fale em “cerca de” e “estimado”. Mostre que você conhece as limitações.

× Mexer em filtros sem saber o resultado

Em vez disso: Ensaie cada clique antes. Se algo der errado, volte para a Visão Geral e siga o roteiro.

× Passar do tempo

Em vez disso: Se o entrevistador interromper com perguntas, ótimo: pule direto para a etapa 5, as recomendações.